

Звіт зі Вступу до Статистики

Студентки 1 курсу

Полоз Дарії

Робота №1

Варіант №8

Тема: Проста лінійна регресія

Мета роботи: Провести аналіз залежності між цінами на два різних товари/послуги у різних містах Європи.


1. На сайті numbeo.com, я знайшла значення цін на обід та молоко в десяти містах Європи відповідно варіанту №8
2. Я прочитала файл з моїми даними в R у вигляді фрейму даних:

```
cost <- read.table("I:/lab1.txt", header = TRUE)
```

В результаті отримала таблицю:

	City	Meal	Milk
1	Warsaw	9.50	0.98
2	Krakow	9.50	1.02
3	Prague	10.31	1.08
4	Brno	8.25	1.03
5	Budapest	10.51	1.06
6	Debrecen	11.82	1.04
7	Bucharest	11.78	1.41
8	Constanta	11.78	1.58
9	Sofia	10.23	1.65
10	Gabrovo	10.23	1.43

3. Я вивела діаграму розсіювання для досліджуваних цін разом з назвами міст:



4. Я підрахувала оцінки методу найменшого квадрату для коефіцієнтів простої лінійної регресії між досліджуваними цінами за теоретичними формулами, використовуючи арифметичні дії в R:

```
x <- cost$Meal
```

```
y <- cost$Milk
```

```
n <- length(x)
```

```
b1 <- (sum(x*y)/n - sum(x)/n * sum(y)/n) / (sum(x*x)/n - sum(x)/n * sum(x)/n)
```

```
b0 <- sum(y)/n - b1 * sum(x)/n
```

В результаті отримала значення $b_0 = 0.205728$ та $b_1 = 0.098380$


5. Я підрахувала ті самі оцінки, використовуючи функцію `lm()` в R:

```
lm(Milk~Meal, data=cost)
```

В результаті отримала $b_0 = 0.20573$ та $b_1 = 0.09838$. Отримані результати з пункту 4 та за допомогою функції `lm()` майже не відрізняються, різниця зумовлена лише округленням результатів

6. На діаграмі розсіювання намалювала лінію регресії за МНК:

```
abline(b0, b1, col="red")
```



7. На діаграмі спостерігається слабка позитивна лінійна залежність — з ростом ціни на молоко ціна на їжу також незначно зростає. Також можна помітити два слабких кластери: перший — міста з доволі низькою ціною на молоко, та середньою ціною на їжу: Warsaw, Krakow, Budapest, Prague; другий — міста з вищою ціною на молоко і відповідно високою ціною на їжу: Gabrovo, Sofia, Bucharest, Constanta.

На діаграмі виявлено очевидний викид. Sofia — має дуже високе значення Milk, в порівнянні з іншими містами в цій категорії має середні ціни на їжу, що значно вище лінії регресії.

8. Я спробувала видалити викид з набору даних та подивитися на зміни:

```
x<-x[-9]
```

```
y<-y[-9]
```


Далі підрахувала оцінки методу найменшого квадрату для коефіцієнтів простої лінійної регресії між досліджуваними цінами без викиду:

```
n<-length(x)
```

```
b1<-(sum(x*y)/n-sum(x)/n*sum(y)/n)/(sum(x*x)/n-sum(x)/n*sum(x)/n)
```

```
b0<-sum(y)/n-b1*sum(x)/n
```

В результаті отримала $b_0 = 0.089791$ та $b_1 = 0.104844$. Побудувала лінію регресії з новими коефіцієнтами: `abline(b0, b1, col="lightgreen")`



Лінія регресії без урахування цін Софії виглядає значно краще, адже можна помітити що вона дійсно тягнула лінію вгору. Тому, зелена лінія (без значення Софії) краще відображає тенденцію у даних.

10. Я вирішила розглянути ще 10 міст з тих країн, з яких була взята попередня вибірка.

Я прочитала файл з моїми даними в R у вигляді фрейму даних і отримала таблицю:

```
cost2 <- read.table("I:/lab1_1.txt", header = TRUE)
```

	City	Meal	Milk
1	Warsaw	9.50	0.98
2	Krakow	9.50	1.02
3	Prague	10.31	1.08
4	Brno	8.25	1.03
5	Budapest	10.51	1.06
6	Debrecen	11.82	1.04
7	Bucharest	11.78	1.41
8	Constanta	11.78	1.58
9	Sofia	10.23	1.65
10	Gabrovo	10.23	1.43
11	Lodz	9.47	0.94
12	Wroclaw	9.20	0.97
13	Ostrava	9.10	1.06
14	Miskolc	9.80	1.01
15	Cluj-Napoca	10.50	1.32
16	Plovdiv	9.50	1.52
17	Timisoara	10.20	1.36
18	Varna	9.90	1.48
19	Gdansk	9.10	0.95
20	Pecs	9.70	1.00

Я підрахувала оцінки методу найменшого квадрату для коефіцієнтів простої лінійної регресії між досліджуваними цінами:

```
x<-cost2$Meal
```

```
y<-cost2$Milk
```

```
n<-length(x)
```

```
b1<-((sum(x*y)/n-sum(x)/n*sum(y)/n)/(sum(x*x)/n-sum(x)/n*sum(x)/n)
```

```
b0<-sum(y)/n-b1*sum(x)/n
```

В результаті отримала $b_0 = 0.019093$ та $b_1 = 0.117321$

Підрахувала ті самі оцінки, використовуючи функцію. `lm()` в R:


```
lm(Milk~Meal, data=cost2)
```

В результаті отримала $b_0 = 0.01909$ та $b_1 = 0.11732$

Отримані оцінки за двома методами практично однакові, різниця зумовлена лише округленням результатів. Якщо порівнювати з минулими результатами, то можна помітити, що b_1 збільшився, тоді як коефіцієнт b_0 зменшився.


Намалювала нову лінію регресії за МНК:

```
abline(b0, b1, col="blue")
```



Можна помітити два кластери: перший- має дуже близькі значення Milk~Meal (Ostrava, Wroclaw, Krakow, Miskolc, Warsaw, Gdansk, Lodz, Prague, Budapest, Pecs), другий- подібні ціни на їжу(Plovdiv, Varna, Gabrovo, Timisoara, Cluj-Napoca)


Я побудувала лінію регресії, яка була при вибірці з 10 міст:



Можна помітити, що при додаванні нових даних прогнозовані ціни на обід стали вищими, ніж при минулих спостереженнях. Це пояснюється збільшенням коефіцієнта b_1 . (червона лінія - для 10 міст, синя - для 20 міст). В цьому випадку викидом також є Софія.

Можна знову спробувати видалити її, підрахувати оцінки МНК для коефіцієнтів простої лінійної регресії між досліджуваними цінами без викиду та намалювати нову лінію регресії:

```
x<-x[-9]
y<-y[-9]
n<-length(x)
b1<-(sum(x*y)/n-sum(x)/n*sum(y)/n)/(sum(x*x)/n-sum(x)/n*sum(x)/n)
b0<-sum(y)/n-b1*sum(x)/n
abline(b0, b1, col="green")
```



Аналогічно до попереднього випадку можна помітити, що лінія регресії без урахування цін Софії виглядає значно краще, адже вона хоч і з невеликою різницею, але тягнула лінію вгору Тому, зелена лінія(без значення Софії) краще відображає тенденцію у даних і в цьому випадку.

Висновки: Під час роботи я провела аналіз залежності між цінами на молоко та обід у різних містах Східної Європи. Спочатку я розглянула вибірку з 10 міст та побудувала лінію регресії. Я помітила явний викид — місто Софія, де реальна ціна на молоко явно перевищує прогнозовану. Лінія регресії без Софії показала кращу відповідність загальній тенденції.

Потім було розглянуто вибірку з 20 міст. У цьому випадку прогнозовані ціни на молоко змінились через вплив нових даних — коефіцієнт b_1 збільшився з 0.0984 до 0.1173, що свідчить про більш виражену залежність при більшій кількості спостережень. Софія залишилась викидом і у розширеній вибірці.

Також було помічено чітку кластеризацію даних: польські та чеські міста утворюють кластер з низькими цінами на молоко, тоді як болгарські та румунські — кластер з вищими цінами, що пояснюється економічними відмінностями між країнами.

Отже, можна зробити висновок, що залежність між ціною на молоко та обід є слабкою позитивною лінійною регресією, проте значно змінюється від наявності викидів та складу вибірки. Без викиду Софії зв'язок між змінними краще відображає загальну тенденцію.

Код:

```
cost <- read.table("I:/lab1.txt", header = TRUE)
plot(cost$Meal, cost$Milk, col="pink", xlim=c(7.9,12), ylim=c(0.9,1.7),
      xlab="Meal", ylab="Milk", pch=18)
text(cost$Meal, cost$Milk, labels=cost$City, col="#54a2e0", pos=2, cex=1)
x <- cost$Meal
y <- cost$Milk
n <- length(x)
b1 <- (sum(x*y)/n - sum(x)/n * sum(y)/n) / (sum(x*x)/n - sum(x)/n * sum(x)/n)
b0 <- sum(y)/n - b1 * sum(x)/n
lm(Milk ~ Meal, data=cost)
abline(b0, b1, col="red")
x<-x[-9]
y<-y[-9]
n<-length(x)
b1<-(sum(x*y)/n-sum(x)/n*sum(y)/n)/(sum(x*x)/n-sum(x)/n*sum(x)/n)
b0<-sum(y)/n-b1*sum(x)/n
abline(b0, b1, col="lightgreen")
cost2 <- read.table("I:/lab1_1.txt", header = TRUE)
plot(cost2$Meal, cost2$Milk, col="pink", xlim=c(7.9,12), ylim=c(0.9,1.7),
      xlab="Meal", ylab="Milk", pch=18)
```

```
text(cost2$Meal, cost2$Milk, labels=cost2$City, col="#54a2e0", pos=2, cex=1)
x<-cost2$Meal
y<-cost2$Milk
n<-length(x)
b1<-((sum(x*y)/n-sum(x)/n*sum(y)/n)/(sum(x*x)/n-sum(x)/n*sum(x)/n)
b0<-sum(y)/n-b1*sum(x)/n
lm(Milk~Meal, data=cost2)
abline(b0, b1, col="blue")
x<-x[-9]
y<-y[-9]
n<-length(x)
b1<-((sum(x*y)/n-sum(x)/n*sum(y)/n)/(sum(x*x)/n-sum(x)/n*sum(x)/n)
b0<-sum(y)/n-b1*sum(x)/n
abline(b0, b1, col="green")
```